

Das AI-Visibility-Evidenzmodell.

Fünf publisher-seitige Faktoren nach Evidenzstärke.

Stefan Petschinka

ORCID: 0009-0009-8223-0339

Veröffentlicht von: richresults.ai

Version: 1.0

Erstveröffentlichung: 30. Juli 2026

DOI: 10.5281/zenodo.21766951

Lizenz: Creative Commons Namensnennung 4.0 International (CC BY 4.0)

<https://www.richresults.ai/de/evidenz.html>

EMPFOHLENE ZITIERWEISE

Petschinka, Stefan (2026). *Das AI-Visibility-Evidenzmodell*. Version 1.0. DOI: 10.5281/zenodo.21766951.

Was das AI-Visibility-Evidenzmodell ist.

Das AI-Visibility-Evidenzmodell ist ein Referenzmodell, das die publisher-seitigen Faktoren hinter AI Visibility nach Evidenzstärke ordnet. Es definiert fünf Faktoren: Topical Relevance, Machine Access, Entity Consistency, Extractability und Independent Corroboration und weist jedem einen dokumentierten Evidenzgrad zu, gestützt auf peer-reviewte Forschung, kontrollierte Preprint-Studien und offizielle Plattformdokumentation.

Das Modell existiert, weil dem Feld weiterhin eine kompakte publisher-seitige Referenz fehlt, die die zentralen handlungsrelevanten Faktoren expliziten Evidenzgraden und Primärquellen zuordnet. Jeder Faktor trägt seinen Grad und seine Quellen, sodass jede Aussage in diesem Dokument gegen die unten aufgeführten Originalstudien und offiziellen Dokumentationen geprüft werden kann.

02 ZWECK UND ABGRENZUNG

Eine Karte der Evidenz, keine Methodik.

Das AI-Visibility-Evidenzmodell kartiert, was die Evidenz als wirksam ausweist. Das AEO Mastery Framework beschreibt, wie richresults.ai es umsetzt. Das Modell ist deskriptiv: Es berichtet den Stand der Forschung. Das Framework ist präskriptiv: Es definiert eine Arbeitsmethode. Keines ersetzt das andere.

Das Modell ist kein Rankingsystem, kein Score und kein Ergebnisversprechen. AI Visibility ist eine Verteilung über wiederholte, nichtdeterministische Antworten und kein Faktor dieses Modells garantiert eine Zitation. Was das Modell liefert, ist Priorität: Es zeigt, welche Arbeit durch Evidenz gestützt ist, welche Arbeit Hygiene ist und welcher Arbeit die Evidenz widerspricht. Das klingt bescheidener, als es ist. Wer weiß, welcher Faktor auf welcher Evidenz steht, weiß auch, womit er anfängt und was warten kann. Genau diese Auskunft gibt ein Ergebnisversprechen nicht her.

Eine Grenze ist bewusst gezogen: Das Modell ordnet die Faktoren, an denen ein Publisher arbeiten kann. Die Retrieval-Stufe selbst, also welche Engine welche Quellen auswählt, wie sie sie rankt und wo sie sie im Modellkontext platziert, ist systemseitig. Kontrollierte Arbeiten zeigen, dass diese Stufe die Zitationsergebnisse dominiert [2] und Plattformdokumentation beschreibt engine-spezifische Retrieval-Entscheidungen, einschließlich der Frage, wann ein System überhaupt groundet [13]. Alle fünf Faktoren arbeiten dieser Stufe zu; keiner kontrolliert sie.

Vier Grade, vor der Anwendung definiert.

Grad A: peer-reviewed und kontrolliert, oder unabhängig repliziert.

Grad B: kontrolliert mit begrenzter Übertragbarkeit auf offene Produktionssysteme, oder eine offizielle Plattformaussage.

Grad C: korrelational oder über unabhängige Datensätze trianguliert, ohne kausalen Nachweis.

Grad D: unbelegt oder durch Evidenz widerlegt.

Jeder Faktor trägt zusätzlich seinen Mechanismustyp. Ein Tor ist eine binäre Voraussetzung, ein Treiber beeinflusst Ergebnisse graduell und Hygiene reduziert Fehler, ohne einen Vorteil zu erzeugen.

Mechanismustyp und Evidenzgrad sind getrennte Dimensionen: Ein Faktor kann ein hartes Tor mit schwacher empirischer Evidenz sein, oder ein weicher Treiber mit starker Evidenz.

Diese vier Grade sind die eigene Skala dieses Modells und sie ist bewusst konservativ. Ein Faktor mit Grad C ist nicht unwichtig; es bedeutet, dass niemand seinen kausalen Effekt in Produktionssystemen isoliert hat und wer anderes behauptet, behauptet mehr, als die Daten tragen. Grade wandern, wenn Evidenz hinzukommt und dieses Dokument trägt dafür eine sichtbare Version und ein Datum.

04 DIE FÜNF FAKTOREN

Faktor 1: Topical Relevance

Inhalt, der die tatsächliche Frage direkt beantwortet, ist der stärkste dokumentierte inhaltsseitige Zitationstreiber. In der bislang größten kontrollierten Zitationsstudie, 252.000 Versuche über sechs Sprachmodelle, waren thematische Passung zur Anfrage und Position im Modellkontext die dominanten Faktoren und themenfremder Inhalt wurde praktisch nie zuerst zitiert [1]. Kontrollierte Arbeiten bestätigen dasselbe Muster von der Modellseite: Beim Abwägen widersprüchlicher Belege stützen sich Modelle stark auf die Relevanz einer Seite zur Anfrage und ignorieren stilistische Autoritätssignale wie wissenschaftlich wirkende Referenzen oder neutralen Ton weitgehend [14]. Keine Entitätsarbeit, kein Markup und kein Autoritätssignal kompensiert Inhalte, die die gestellte Frage nicht beantworten.

Mechanismus: Treiber. Evidenzgrad: A. Peer-reviewed, kontrolliert, konvergent über Modelle und Studiendesigns [1, 2, 14].

Faktor 2: Machine Access

Eine Quelle, die Crawler nicht erreichen, kann nicht abgerufen werden und eine Quelle, die nicht abgerufen wird, kann inhaltlich nicht für eine Antwort genutzt werden. Machine Access umfasst Crawl-Freigaben für die relevanten Bots, Indexpräsenz, crawlbaren und renderbaren Hauptinhalt sowie Firewall-Konfigurationen, die KI-Crawler nicht stillschweigend blockieren. Die Plattformdokumentation ist auf beiden Seiten dieses Tors eindeutig. OpenAI setzt den Zugriff von OAI-SearchBot voraus, damit Seiteninhalte in ChatGPT-Suchantworten genutzt werden; ausgeschlossene Seiten können weiterhin als Navigationslinks erscheinen [12]. Google verlangt indexierte, snippet-fähige Seiten und erklärt, dass seine KI-Funktionen auf demselben Index und denselben Rankingsystemen laufen wie die klassische Suche [11].

Mechanismus: Tor. Evidenzgrad: B, offizielle Plattformdokumentation. Ohne Zugriff kann der Inhalt einer Seite nicht für eine Antwort abgerufen werden; Zugriff allein erzeugt keinen Vorteil, keine Abruf-Garantie und keine Zitations-Garantie [11, 12].

Faktor 3: Entity Consistency

Konsistente Entitätssignale unterstützen die Zuordnung relevanter Inhalte zur richtigen Quelle. Strukturierte Daten, stabile Identifikatoren, kanonische Namensstrings und verbundene externe Profile können Mehrdeutigkeit bei der Auflösung reduzieren, wer spricht. Der dokumentierte Effekt ist Fehlerreduktion und Disambiguierung, kein Sichtbarkeits-Boost: Google erklärt, dass für seine KI-Funktionen kein spezielles Markup erforderlich ist [11] und kontrollierte Arbeiten zeigen, dass Knowledge-Graph-Fundierung Disambiguierungsfehler in Benchmark-Settings reduziert [15]. Ein direkter kausaler Effekt auf Zitations- oder Nennungsraten in produktiven Answer Engines ist bislang nicht nachgewiesen; die Übertragung ist Inferenz.

Mechanismus: Hygiene. Evidenzgrad: C. Offizielle Plattformaussagen und Benchmark-Evidenz für Disambiguierung; kein kausaler Nachweis als Zitationstreiber [11, 15].

Faktor 4: Extractability

Was ein Modell zitieren soll, muss es zuerst herauslösen können. Die Position von Information im Modellkontext verändert Ergebnisse kausal [3, 4] und Seiten mit konkreten Zahlen, Definitionen, Vergleichen und Prozeduren zeigen deutlich höheren Einfluss auf generierte Antworten als Seiten ohne sie [7]. Die Grenze ist ebenso dokumentiert: Diese Effekte gelten nach dem Retrieval, der Einfluss-Befund ist deskriptiv und korrelational [7], reine Frage-Antwort-Formatierung hilft nicht [7] und Umschreibe-Tricks zeigen keinen verlässlichen Effekt und sind unter Wettbewerb häufig schädlich [2]. Eine Übertragung bleibt Inferenz: Ein Publisher kontrolliert nicht, welche Passage ein Retriever auswählt und wo dieser Chunk im Modellkontext landet. Aussage-zuerst-Seitenstruktur ist deshalb ein plausibler Weg, der Extraktion zuzuarbeiten, kein nachgewiesener Positionshebel.

Mechanismus: Treiber. Evidenzgrade, aufgeteilt: B für Positionseffekte als Modellphänomen [3, 4] und für Evidenzdichte im fixierten Kontext [6]; C für Aussage-zuerst-Seitenstruktur als Publisher-Taktik; korrelational in Produktion [7], begrenzt durch [2] und [9].

Faktor 5: Independent Corroboration

Nennungen durch Dritte sind der klassische Weg in das parametrische Wissen eines Modells und die Evidenz dieses Faktors liest sich am ehrlichsten als drei getrennte Aussagen. Erstens zeigt kontrollierte Forschung, dass die Häufigkeit entitätsbezogener Evidenz über Trainingsdokumente hinweg kausal beeinflusst, was ein Modell ohne Suche über die Entität weiß; über die Unabhängigkeit dieser Dokumente trifft die Studie keine Aussage [5]. Zweitens berichtet eine Preprint-Analyse, dass mehrere KI-Suchsysteme eine starke Präferenz für Earned Media gegenüber markeneigenen Inhalten zeigen, auf Basis der eigenen Quellenklassifikation der Autoren [8]. Drittens ist die Aussage, dass die Unabhängigkeit oder Echtheit einer Nennung selbst höhere AI Visibility verursacht, durch keine der beiden Quellen nachgewiesen. Das praktische Prinzip steht auf methodischem Grund und zwar unabhängig von [5]: Selbstpublizierte Korroborationsnetzwerke replizieren eine Stimme in vielen Kostümen, liefern keine unabhängige Bestätigung und können gegen Plattformrichtlinien verstoßen; für fabrizierte Nennungen existiert kein belastbarer Nachweis eines positiven Effekts.

Mechanismus: Treiber für die parametrische Schicht. Evidenzgrade, aufgeteilt: B für Trainingsdaten-Häufigkeit als kausalen Faktor parametrischen Wissens [5]; C für die beobachtete Earned-Media-Präferenz [8]; unbelegt für Unabhängigkeit selbst als kausalen Sichtbarkeitsfaktor.

Grad D, aus unterschiedlichen Gründen.

llms.txt als Sichtbarkeitshebel. Google erklärt ausdrücklich, llms.txt weder für die Suche noch für generative Suchfunktionen zu verwenden [11]. Im hier ausgewerteten Quellenbestand dokumentiert keine Plattform die Datei als Ranking- oder Sichtbarkeitssignal.

Umschreibe-Tricks auf Inhaltsebene. Der breiteste kontrollierte Benchmark fand die meisten Conversational-Optimierungsmethoden wirkungslos und häufig schädlich für die Zitationsrangfolge, während die klassische Retrieval-Position dominierte [2].

Schema als Zitationsschalter. Strukturierte Daten klären und disambiguieren. Als direkter Zitationstreiber für KI-Funktionen sind sie offiziell nicht erforderlich [11] und für Sprachmodell-Zitationen außerhalb von Such-Pipelines existiert kein kausaler Beleg.

KI-Rankingpositionen als Metrik. Antworten variieren stark über ansonsten identische Läufe hinweg; eine Position aus einem einzelnen Lauf ist deshalb kein belastbarer Rang [9]. Aussagekräftig werden Positionen erst als Verteilung über wiederholte, paraphrasierte Messungen mit Unsicherheitsintervallen; Sichtbarkeit ist ein Anteil, kein Einzelrang.

Fabrizierte Nennungen. Für fabrizierte oder selbst erzeugte Nennungen existiert kein belastbarer Nachweis eines positiven Effekts. In der Literatur wird die Grenze zwischen Optimierung und Manipulation nicht durch Wirksamkeit bestimmt, sondern durch Wahrheitstreue, verifizierbare Belege, die Trennung von Inhalt und Modellanweisung sowie die Offenlegung kommerzieller Absicht [9]. Was dieses Modell zu Korroboration sagt, stützt sich auf Trainingsdaten-Häufigkeit [5] und eine beobachtete Earned-Media-Präferenz [8]; selbst erzeugte Nennungen untersucht keine dieser Arbeiten.

06 SICHTBARKEIT IST NICHT ZITATIONSTREUE

Zitiert werden und korrekt zitiert werden sind verschiedene Ergebnisse.

Ein unabhängiges Audit von acht KI-Suchsystemen ergab, dass die Systeme gemeinsam mehr als 60 Prozent der Quellenzuordnungs-Anfragen falsch beantworteten, wobei Premium-Systeme häufig selbstsicher falsch lagen [10]. Für jede Organisation hat das zwei Konsequenzen: Zitationszahlen überzeichnen die Kontrolle darüber, was tatsächlich gesagt wird und die Zitationsfrequenz allein sagt wenig darüber aus, ob eine Organisation korrekt dargestellt und der ursprünglichen Quelle richtig zugeordnet wird. Ein Messprogramm sollte Treue, also die Frage, ob die Aussagen eines Systems über die Entität zutreffen, deshalb getrennt von Sichtbarkeit erfassen.

Wie dieses Modell kompiliert wurde.

Jede Aussage dieses Modells wurde gegen ihre Quelle verifiziert: die Papers, offiziellen Dokumentationen und Datensätze im Register unten. Die Synthese wurde zusätzlich auf Vollständigkeit und Gegenargumente geprüft, indem mehrere KI-Systeme dieselbe Evidenzfrage ohne Zugriff auf dieses Modell erhielten. Konvergenz über Systeme hinweg ist ein redaktioneller Plausibilitätscheck, keine unabhängige wissenschaftliche Validierung: Systeme teilen Trainingsdaten, Quellen und Fehlermuster und können auf denselben populären Irrtum konvergieren.

Offenlegung: Dieses Referenzmodell wird von richresults.ai veröffentlicht und von Stefan Petschinka verfasst, der auch das verlinkte AEO Mastery Framework entwickelt hat. Die Quellenbewertung, die Synthese und die Evidenzgrade sind Eigenleistungen des Autors und wurden keinem externen Peer Review unterzogen.

Drei Grenzen gelten für alles in diesem Dokument. Produktionssysteme sind nichtdeterministisch, also beweist keine Einzelbeobachtung einen Effekt. Modelle und Retrieval-Methoden ändern sich ohne Ankündigung, also tragen Befunde Datumsangaben. Und niemand, auch nicht die beste publizierte Forschung, kann eine einzelne Intervention innerhalb einer laufenden Answer Engine kausal isolieren. Wo dieses Dokument sagt, dass die Evidenz endet, endet sie.

ÜBER DEN AUTOR



Stefan Petschinka.

AEO Strategist · Entity Architect · Gründer von richresults.ai

Stefan Petschinka ist AEO Strategist, Entity Architect und Gründer von richresults.ai. Stefan Petschinka ist spezialisiert auf KI-Sichtbarkeit, Answer Engine Optimization, Generative Engine Optimization, Large Language Model Optimization und Entity Building. Seine Arbeit schafft KI-Sichtbarkeit durch Entity Building: die maschinenlesbare Identitätsschicht, die Organisationen, Marken und Experten für ChatGPT, Perplexity, Claude, Gemini und Google AI Search verständlich, zitierfähig und empfehlenswert macht. Stefan Petschinka ist Autor zweier Sachbücher über die Funktionsweise von KI-Sprachmodellen: FEED THE MACHINE und ECHO: Die dunkle Psychologie der KI.

Web: <https://www.richresults.ai/de/stefan-petschinka.html> · ORCID: 0009-0009-8223-0339

Nummeriert wie oben zitiert.

1. Vishwakarma, Kumar, Jamidar (2026). What Gets Cited: Competitive GEO in AI Answer Engines. SIGIR 2026. DOI:10.1145/3805712.3808445, arXiv:2605.25517. Peer-reviewed; Autoren bei Sprinklr beschäftigt.
2. Puerto et al. (2025). C-SEO Bench: Does Conversational SEO Work? NeurIPS 2025 Datasets and Benchmarks. arXiv:2506.11097.
3. Liu et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. TACL 2024. arXiv:2307.03172.
4. Hsieh et al. (2024). Found in the Middle: Calibrating Positional Attention Bias. ACL 2024 Findings. arXiv:2406.16008.
5. Kandpal et al. (2023). Large Language Models Struggle to Learn Long-Tail Knowledge. ICML 2023. arXiv:2211.08411.
6. Aggarwal et al. (2024). GEO: Generative Engine Optimization. KDD 2024. arXiv:2311.09735. Effekte bedingt auf fixierte Kontexte; siehe [2] und [9].
7. Zhang, He, Yao (2026). From Citation Selection to Citation Absorption. Preprint. arXiv:2604.25707.
8. Chen, Wang, Chen, Koudas (2025). Generative Engine Optimization: How to Dominate AI Search. Preprint, University of Toronto. arXiv:2509.08919. Danksagung an ktai.ai vermerkt.
9. Martinez (2026). Optimizing Visibility in Generative Engines: A Critical Survey. Preprint. arXiv:2607.14035.
10. Jaźwińska, Chandrasekar (2025). AI Search Has a Citation Problem. Tow Center, Columbia Journalism Review. cjr.org.
11. Google Search Central: AI features and your website. developers.google.com. Sowie: Optimizing your website for generative AI features on Google Search. developers.google.com.
12. OpenAI: OAI-SearchBot-Dokumentation. openai.com/searchbot. Sowie: Publishers and Developers FAQ. help.openai.com.
13. Google AI for Developers: Grounding with Google Search. ai.google.dev. Dokumentiert engine-seitige Retrieval-Entscheidungen; keine Publisher-Teilnahmebedingung.
14. Wan, Wallace, Klein (2024). What Evidence Do Language Models Find Convincing? ACL 2024, Seiten 7468–7484. DOI:10.18653/v1/2024.acl-long.403, arXiv:2402.11782.
15. Pons, Bilalli, Queralto (2024). Knowledge Graphs for Enhancing Large Language Models in Entity Disambiguation. Proc. 23rd Int. Semantic Web Conference (ISWC 2024), LNCS, Springer. DOI:10.1007/978-3-031-77844-5_9, arXiv:2505.02737.