

Das AI-Visibility-Evidenzmodell.

Fünf publisher-seitige Faktoren nach Evidenzstärke.

Stefan Petschinka

ORCID: 0009-0009-8223-0339

Veröffentlicht von: richresults.ai

Version: 1.0

Erstveröffentlichung: 30. Juli 2026

Überarbeitet: 30. August 2026

DOI: 10.5281/zenodo.21766951

Lizenz: Creative Commons Namensnennung 4.0 International (CC BY 4.0)

<https://www.richresults.ai/de/evidenz.html>

EMPFOHLENE ZITIERWEISE

Petschinka, Stefan (2026). *Das AI-Visibility-Evidenzmodell*. Version 1.0. DOI: 10.5281/zenodo.21766951.

Was das AI-Visibility-Evidenzmodell ist.

Das AI-Visibility-Evidenzmodell ist ein Referenzmodell, das die publisher-seitigen Faktoren hinter AI Visibility nach Evidenzstärke ordnet. Es definiert fünf Faktoren: Topical Relevance, Machine Access, Entity Consistency, Extractability und Independent Corroboration und weist jedem einen dokumentierten Evidenzgrad zu, gestützt auf peer-reviewte Forschung, kontrollierte Preprint-Studien und offizielle Plattformdokumentation.

Das Modell existiert, weil dem Feld weiterhin eine kompakte publisher-seitige Referenz fehlt, die die zentralen handlungsrelevanten Faktoren expliziten Evidenzgraden und Primärquellen zuordnet. Jeder Faktor trägt seinen Grad und seine Quellen, sodass jede Aussage in diesem Dokument gegen die unten aufgeführten Originalstudien und offiziellen Dokumentationen geprüft werden kann.

Eine Karte der Evidenz, keine Methodik.

Das AI-Visibility-Evidenzmodell kartiert, was die Evidenz als wirksam ausweist. Das AEO Mastery Framework beschreibt, wie richresults.ai es umsetzt. Das Modell ist deskriptiv: Es berichtet den Stand der Forschung. Das Framework ist präskriptiv: Es definiert eine Arbeitsmethode. Keines ersetzt das andere.

Das Modell liefert eine evidenzbasierte Ordnung für publisher-seitige Arbeit an AI Visibility. Es zeigt, welche Faktoren als Treiber gestützt sind, welche als dokumentierte Voraussetzungen oder Mechanismen zur Fehlerreduktion wirken und welche Aussagen von der aktuellen Evidenz nicht gestützt werden. AI Visibility bleibt eine Verteilung über wiederholte, nichtdeterministische Antworten; deshalb ist das Modell weder Rankingsystem noch Score noch Versprechen einer bestimmten Zitation. Sein praktischer Wert liegt in der Priorität: Es zeigt, wo Publisher an evidenzgestützten Mechanismen arbeiten können und wie stark jeder Mechanismus dokumentiert ist.

Eine Grenze ist bewusst gezogen: Das Modell ordnet die publisher-seitigen Faktoren, an denen vor und rund um Retrieval gearbeitet werden kann. Die Retrieval-Stufe selbst, also welche Engine welche Quellen auswählt, wie sie sie rankt und wo sie sie im Modellkontext platziert, ist systemseitig. Kontrollierte Arbeiten zeigen, dass diese Stufe die Zitationsergebnisse stark prägt [2] und Plattformdokumentation beschreibt engine-spezifische Retrieval-Entscheidungen, einschließlich der Frage, wann ein System überhaupt groundet [13]. Alle fünf Faktoren sind publisher-seitige Inputs in diesen Prozess. Das Modell trennt damit, was Publisher verbessern können, von der finalen Retrieval-Entscheidung der Engine, ohne fehlende Kontrolle über diese letzte Entscheidung als Evidenz gegen die Wirksamkeit publisher-seitiger Arbeit zu behandeln.

Vier Grade, vor der Anwendung definiert.

Grad A: peer-reviewed und kontrolliert, oder unabhängig repliziert.

Grad B: kontrolliert mit begrenzter Übertragbarkeit auf offene Produktionssysteme, oder eine offizielle Plattformaussage.

Grad C: korrelational oder über unabhängige Datensätze trianguliert, ohne kausalen Nachweis.

Grad D: unbelegt oder durch Evidenz widerlegt.

Jeder Faktor trägt zusätzlich seinen Mechanismustyp. Ein Tor ist eine binäre Voraussetzung, ein Treiber beeinflusst Ergebnisse graduell und Hygiene reduziert Fehler oder Mehrdeutigkeit. Mechanismustyp und Evidenzgrad sind getrennte Dimensionen: Ein Faktor kann ein hartes Tor mit schwacher empirischer Evidenz sein, oder ein weicher Treiber mit starker Evidenz. Die Einordnung als Hygiene bedeutet nicht, dass ein Faktor keinen Sichtbarkeitsvorteil erzeugt; sie bedeutet, dass der in diesem Modell dokumentierte Mechanismus primär Fehlerreduktion oder Disambiguierung ist, während ein unabhängiger Sichtbarkeitseffekt durch die zitierten Quellen nicht isoliert wurde.

Diese vier Grade sind die eigene Skala dieses Modells und sie ist bewusst konservativ. Ein Faktor mit Grad C kann praktisch relevant sein: Die vorhandene Evidenz ist korrelational, trianguliert oder aus Benchmark-Settings übertragen, statt in offenen Produktionssystemen kausal isoliert zu sein. Grad C begrenzt damit die Stärke der Aussage; fehlender Kausalnachweis wird nicht zu Evidenz für fehlende Wirkung. Grade wandern, wenn Evidenz hinzukommt und dieses Dokument trägt dafür ein sichtbares Revisionsdatum.

04 DIE FÜNF FAKTOREN

Faktor 1: Topical Relevance

Inhalt, der die tatsächliche Frage direkt beantwortet, ist der stärkste dokumentierte inhaltsseitige Zitationstreiber. In der bislang größten kontrollierten Zitationsstudie, 252.000 Versuche über sechs Sprachmodelle, waren thematische Passung zur Anfrage und Position im Modellkontext die dominanten Faktoren und themenfremder Inhalt wurde praktisch nie zuerst zitiert [1]. Kontrollierte Arbeiten bestätigen dasselbe Muster von der Modellseite: Beim Abwägen widersprüchlicher Belege stützen sich Modelle stark auf die Relevanz einer Seite zur Anfrage und ignorieren stilistische Autoritätssignale wie wissenschaftlich wirkende Referenzen oder neutralen Ton weitgehend [14]. Keine Entitätsarbeit, kein Markup und kein Autoritätssignal kompensiert Inhalte, die die gestellte Frage nicht beantworten.

Mechanismus: Treiber. Evidenzgrad: A. Peer-reviewed, kontrolliert, konvergent über Modelle und Studiendesigns [1, 2, 14].

Faktor 2: Machine Access

Eine Quelle, die Crawler nicht erreichen, kann nicht abgerufen werden und eine Quelle, die nicht abgerufen wird, kann inhaltlich nicht für eine Antwort genutzt werden. Machine Access umfasst Crawl-Freigaben für die relevanten Bots, Indexpräsenz, crawlbaren und renderbaren Hauptinhalt sowie Firewall-Konfigurationen, die KI-Crawler nicht stillschweigend blockieren. Die Plattformdokumentation ist auf beiden Seiten dieses Tors eindeutig. OpenAI setzt den Zugriff von OAI-SearchBot voraus, damit Seiteninhalte in ChatGPT-Suchantworten genutzt werden; ausgeschlossene Seiten können weiterhin als Navigationslinks erscheinen [12]. Google verlangt indexierte, snippet-fähige Seiten und erklärt, dass seine KI-Funktionen auf demselben Index und denselben Rankingsystemen laufen wie die klassische Suche [11].

Mechanismus: Tor. Evidenzgrad: B, offizielle Plattformdokumentation. Ohne Zugriff kann der Inhalt einer Seite nicht für eine Antwort abgerufen werden; Machine Access ist damit eine dokumentierte Voraussetzung [11, 12]. Die zitierten Quellen weisen nicht nach, dass Zugriff allein Abruf oder Zitation garantiert, und sie quantifizieren keinen eigenständigen Sichtbarkeits-Uplift durch den Zugriff selbst.

Faktor 3: Entity Consistency

Konsistente Entitätssignale unterstützen die Zuordnung relevanter Inhalte zur richtigen Quelle. Strukturierte Daten, stabile Identifikatoren, kanonische Namensstrings und verbundene externe Profile können Mehrdeutigkeit bei der Auflösung reduzieren, wer spricht. Google erklärt, dass für seine KI-Funktionen kein spezielles Markup erforderlich ist [11]; daraus folgt, dass spezielles Markup keine Teilnahmevoraussetzung ist, nicht dass strukturierte Entity-Signale ohne Wirkung sind. Kontrollierte Arbeiten zeigen, dass Knowledge-Graph-Fundierung Disambiguierungsfehler in Benchmark-Settings reduziert [15]. Die Evidenz stützt Entity Consistency damit als Mechanismus für klarere Entity Resolution und Zuordnung. Ein direkter kausaler Effekt auf Zitations- oder Nennungsraten in produktiven Answer Engines wurde bislang nicht isoliert; deshalb weist dieses Modell dem Faktor keinen eigenständigen Zitations-Uplift zu.

Mechanismus: Hygiene. Evidenzgrad: C. Gestützt für Disambiguierung und Entity Resolution [11, 15]; kein isolierter kausaler Zitations- oder Nennungs-Uplift in produktiven Answer Engines.

Faktor 4: Extractability

Was ein Modell zitieren soll, muss es zuerst herauslösen können. Die Evidenz stützt mehrere konkrete Eigenschaften gut extrahierbarer Information: Die Position von Information im Modellkontext verändert Ergebnisse kausal [3, 4] und Seiten mit konkreten Zahlen, Definitionen, Vergleichen und Prozeduren zeigen deutlich höheren Einfluss auf generierte Antworten als Seiten ohne sie [7]. Das stützt Extractability als praktisches publisher-seitiges Ziel: relevante Fakten explizit, spezifisch und nach dem Retrieval leicht isolierbar zu machen. Die Grenze ist, dass daraus keine universelle Seitenformatierungs-Formel folgt. Der Einfluss-Befund in Produktion ist deskriptiv und korrelational [7], reine Frage-Antwort-Formatierung hilft nicht [7] und Umschreibe-Tricks zeigen keinen verlässlichen Effekt und sind unter Wettbewerb häufig schädlich [2]. Ein Publisher kontrolliert zudem nicht, welche Passage ein Retriever auswählt und wo dieser Chunk im Modellkontext landet; Aussage-zuerst-Seitenstruktur bleibt deshalb eine begründete Publisher-Taktik und kein nachgewiesener Positionshebel.

Mechanismus: Treiber. Evidenzgrade, aufgeteilt: B für kausale Positionseffekte und Evidenzdichte [3, 4, 6]; C für die publisher-seitige Übertragung auf Seitenstruktur und Produktionsumgebungen [7], begrenzt durch [2, 9].

Faktor 5: Independent Corroboration

Nennungen außerhalb der eigenen Publisher-Flächen werden durch zwei relevante Evidenzpfade gestützt. Erstens zeigt kontrollierte Forschung, dass die Häufigkeit entitätsbezogener Evidenz über Trainingsdokumente hinweg kausal beeinflusst, was ein Modell ohne Suche über die Entität weiß [5]. Damit ist wiederholte externe Evidenz als relevanter Input für die parametrische Schicht belegt, auch wenn die Studie die Unabhängigkeit dieser Dokumente nicht isoliert. Zweitens berichtet eine Preprint-Analyse, dass mehrere KI-Suchsysteme eine starke Präferenz für Earned Media gegenüber markeneigenen Inhalten zeigen, auf Basis der eigenen Quellenklassifikation der Autoren [8]. Zusammen stützen diese Befunde externe Korroboration als praktisches publisher-seitiges Ziel: Wichtige Entity-Aussagen stehen stärker, wenn sie auch außerhalb der eigenen Website wiederholt und gestützt werden. Die engere Aussage, dass Unabhängigkeit oder Echtheit für sich genommen höhere AI Visibility verursacht, wurde durch keine der beiden Quellen isoliert; deshalb weist dieses Modell der Unabhängigkeit allein keinen eigenen kausalen Uplift zu. Fabrizierte oder selbst erzeugte Nennungen bleiben als positiver Sichtbarkeitshebel unbelegt.

Mechanismus: Treiber für die parametrische Schicht. Evidenzgrade, aufgeteilt: B für Trainingsdaten-Häufigkeit [5]; C für die beobachtete Earned-Media-Präferenz [8]. Unabhängigkeit selbst wurde nicht als eigener kausaler Sichtbarkeitsfaktor isoliert.

Konkrete Aussagen mit Grad D, aus unterschiedlichen Gründen.

llms.txt als Sichtbarkeitshebel. Google erklärt ausdrücklich, llms.txt weder für die Suche noch für generative Suchfunktionen zu verwenden [11]. Im hier ausgewerteten Quellenbestand dokumentiert keine Plattform die Datei als Ranking- oder Sichtbarkeitssignal.

Umschreiben als verlässlicher Zitationshebel. Der breiteste kontrollierte Benchmark fand die meisten getesteten Conversational-Optimierungsmethoden wirkungslos und häufig schädlich für die Zitationsrangfolge, während die klassische Retrieval-Position dominierte [2]. Die Einstufung mit Grad D gilt für die Aussage, dass Umschreiben allein einen verlässlichen Zitationsvorteil erzeugt, nicht für Topical Relevance oder gut extrahierbare, evidenzreiche Inhalte, die dieses Modell separat bewertet.

Schema als direkter Zitationsschalter. Die Evidenz stützt nicht die Annahme, dass strukturierte Daten als garantierter oder isolierter Zitationsauslöser wirken. Google erklärt, dass spezielles Markup für seine KI-Funktionen nicht erforderlich ist [11] und die hier ausgewerteten Quellen weisen keinen kausalen Zitations-Uplift durch Schema allein nach. Das widerspricht nicht der Rolle strukturierter Daten innerhalb von Entity Consistency: Strukturierte Daten können Entity-Signale klären und disambiguieren, wie in Faktor 3 beschrieben. Die Einstufung mit Grad D gilt für die Behauptung eines direkten Zitationsschalters, nicht für strukturierte Daten als Mechanismus zur Entity-Klärung.

Einzelne KI-Rankingpositionen als stabile Metrik. Antworten variieren stark über ansonsten identische Läufe hinweg; eine Position aus einem einzelnen Lauf ist deshalb kein belastbarer Rang [9]. Aussagekräftig werden Positionen als Verteilung über wiederholte, paraphrasierte Messungen mit Unsicherheitsintervallen; Sichtbarkeit ist ein Anteil, kein Einzelrang.

Fabrizierte Nennungen. Für fabrizierte oder selbst erzeugte Nennungen existiert kein belastbarer Nachweis eines positiven Effekts. In der Literatur wird die Grenze zwischen Optimierung und Manipulation nicht durch Wirksamkeit bestimmt, sondern durch Wahrheitstreue, verifizierbare Belege, die Trennung von Inhalt und Modellanweisung sowie die Offenlegung kommerzieller Absicht [9]. Was dieses Modell zu Korroboration sagt, stützt sich auf Trainingsdaten-Häufigkeit [5] und eine beobachtete Earned-Media-Präferenz [8]; selbst erzeugte Nennungen untersucht keine dieser Arbeiten.

Ein starkes Messprogramm erfasst beides.

Ein unabhängiges Audit von acht KI-Suchsystemen ergab, dass die Systeme gemeinsam mehr als 60 Prozent der Quellenzuordnungs-Anfragen falsch beantworteten, wobei Premium-Systeme häufig selbstsicher falsch lagen [10]. Damit wird Zitationstreue zu einem zweiten Messziel neben Sichtbarkeit. Sichtbarkeit misst, ob und wie häufig eine Entität erscheint; Treue misst, ob das System diese Entität korrekt darstellt und Informationen der richtigen Quelle zuordnet. Beides getrennt zu erfassen unterscheidet erfolgreiche Retrieval- und Zitationsvorgänge von korrekter Darstellung und gibt Organisationen ein vollständigeres Bild ihrer AI Visibility.

Wie dieses Modell kompiliert wurde.

Jede Aussage dieses Modells wurde gegen ihre Quelle verifiziert: die Papers, offiziellen Dokumentationen und Datensätze im Register unten. Die Synthese wurde zusätzlich auf Vollständigkeit und Gegenargumente geprüft, indem mehrere KI-Systeme dieselbe Evidenzfrage ohne Zugriff auf dieses Modell erhielten. Konvergenz über Systeme hinweg ist ein redaktioneller Plausibilitätscheck, keine unabhängige wissenschaftliche Validierung: Systeme teilen Trainingsdaten, Quellen und Fehlermuster und können auf denselben populären Irrtum konvergieren.

Offenlegung: Dieses Referenzmodell wird von richresults.ai veröffentlicht und von Stefan Petschinka verfasst, der auch das verlinkte AEO Mastery Framework entwickelt hat. Die Quellenbewertung, die Synthese und die Evidenzgrade sind Eigenleistungen des Autors und wurden keinem externen Peer Review unterzogen.

Drei Bedingungen bestimmen, wie die Befunde dieses Modells zu lesen sind. Produktionssysteme sind nichtdeterministisch; einzelne Beobachtungen sind deshalb Messungen und kein isolierter Kausalnachweis. Modelle und Retrieval-Methoden verändern sich, deshalb tragen Befunde Datumsangaben und Evidenzgrade können mit neuer Evidenz aktualisiert werden. In laufenden Answer Engines lässt sich eine einzelne publisher-seitige Intervention derzeit nicht durchgängig kausal isolieren; die Evidenzgrade unterscheiden deshalb, was direkt nachgewiesen ist, was aus kontrollierten Settings übertragen wird und was offen bleibt. So bleibt das Modell handlungsorientiert, ohne Sicherheit zu behaupten, die die Evidenz nicht trägt.

ÜBER DEN AUTOR

Stefan Petschinka.

AEO Strategist · Entity Architect · Gründer von richresults.ai

Stefan Petschinka ist AEO Strategist, Entity Architect und Gründer von richresults.ai. Stefan Petschinka ist spezialisiert auf KI-Sichtbarkeit, Answer Engine Optimization, Generative Engine Optimization, Large Language Model Optimization und Entity Building. Seine Arbeit schafft KI-Sichtbarkeit durch Entity Building: die maschinenlesbare Identitätsschicht, die Organisationen, Marken und Experten für ChatGPT, Perplexity, Claude, Gemini und Google AI Search verständlich, zitierfähig und empfehlenswert macht.

Stefan Petschinka ist Autor zweier Sachbücher über die Funktionsweise von KI-Sprachmodellen: FEED THE MACHINE und ECHO: Die dunkle Psychologie der KI.

Web: <https://www.richresults.ai/de/stefan-petschinka.html> · ORCID: 0009-0009-8223-0339

Nummeriert wie oben zitiert.

1. Vishwakarma, Kumar, Jamidar (2026). What Gets Cited: Competitive GEO in AI Answer Engines. SIGIR 2026. DOI:10.1145/3805712.3808445, arXiv:2605.25517. Peer-reviewed; Autoren bei Sprinklr beschäftigt.
2. Puerto et al. (2025). C-SEO Bench: Does Conversational SEO Work? NeurIPS 2025 Datasets and Benchmarks. arXiv:2506.11097.
3. Liu et al. (2024). Lost in the Middle: How Language Models Use Long Contexts. TACL 2024. arXiv:2307.03172.
4. Hsieh et al. (2024). Found in the Middle: Calibrating Positional Attention Bias. ACL 2024 Findings. arXiv: 2406.16008.
5. Kandpal et al. (2023). Large Language Models Struggle to Learn Long-Tail Knowledge. ICML 2023. arXiv: 2211.08411.
6. Aggarwal et al. (2024). GEO: Generative Engine Optimization. KDD 2024. arXiv:2311.09735. Effekte bedingt auf fixierte Kontexte; siehe [2] und [9].
7. Zhang, He, Yao (2026). From Citation Selection to Citation Absorption. Preprint. arXiv:2604.25707.
8. Chen, Wang, Chen, Koudas (2025). Generative Engine Optimization: How to Dominate AI Search. Preprint, University of Toronto. arXiv:2509.08919. Danksagung an ktau.ai vermerkt.
9. Martinez (2026). Optimizing Visibility in Generative Engines: A Critical Survey. Preprint. arXiv:2607.14035.
10. Jaźwińska, Chandrasekar (2025). AI Search Has a Citation Problem. Tow Center, Columbia Journalism Review. cjr.org.
11. Google Search Central: AI features and your website. developers.google.com. Sowie: Optimizing your website for generative AI features on Google Search. developers.google.com.
12. OpenAI: OAI-SearchBot-Dokumentation. openai.com/searchbot. Sowie: Publishers and Developers FAQ. help.openai.com.
13. Google AI for Developers: Grounding with Google Search. ai.google.dev. Dokumentiert engine-seitige Retrieval-Entscheidungen; keine Publisher-Teilnahmebedingung.
14. Wan, Wallace, Klein (2024). What Evidence Do Language Models Find Convincing? ACL 2024, Seiten 7468–7484. DOI:10.18653/v1/2024.acl-long.403, arXiv:2402.11782.
15. Pons, Bilalli, Queralt (2024). Knowledge Graphs for Enhancing Large Language Models in Entity Disambiguation. Proc. 23rd Int. Semantic Web Conference (ISWC 2024), LNCS, Springer. DOI: 10.1007/978-3-031-77844-5_9, arXiv:2505.02737.